

HAPPO

« *S'améliorer ensemble, à coup sûr, quand on est différents* »

Le problème qu'il résout

MAPPO suppose volontiers que les agents sont interchangeables (un même cerveau partagé). Mais ton équipe est faite de **rôles distincts** : un chef, un médecin, un mitrailleur. Surtout, un danger guette toute équipe qui apprend : si **tous se corrigent en même temps**, chacun suppose que les autres ne bougent pas — et tout le monde se trompe ensemble. On appelle ça le « pas de deux catastrophique » : deux agents qui, chacun raisonnant juste de son côté, produisent ensemble une régression. Rien ne garantit alors que l'équipe progresse.

L'idée centrale

On se corrige l'un après l'autre, pas tous à la fois. Chaque agent s'ajuste *en tenant compte* du changement que les précédents viennent de faire. Cet ordre — d'apparence anodine — suffit à **garantir mathématiquement** que l'équipe ne recule jamais d'une étape à l'autre (amélioration dite *monotone*). C'est la grande force théorique de HAPPO.

Le mécanisme, pas à pas

1. On fige une référence : la politique d'équipe actuelle.
2. **Agent 1** calcule sa meilleure petite correction (à la PPO, avec la laisse ε) et l'applique.
3. **Agent 2** calcule la sienne, mais **en intégrant** ce que l'agent 1 a déjà changé.
4. **Agent 3**, puis 4, de même — chacun voit l'effet cumulé des précédents.
5. L'ordre peut être tiré au hasard à chaque tour, pour ne privilégier personne.
6. Comme chacun ne fait qu'un petit pas (laisse ε) et tient compte des autres, le total des pas améliore l'équipe sans la déstabiliser.

Les formules, traduites

① La mise à jour en cascade.

agent 1 se corrige → agent 2 se corrige (sachant le pas de 1) → agent 3 (sachant 1 et 2) →
...

Pour un littéraire : des musiciens qui s'accordent **à tour de rôle**. S'ils tendaient tous leur corde en même temps sans s'écouter, l'orchestre sonnerait faux ; en s'accordant l'un après l'autre, chacun se règle sur ce que les précédents ont déjà fait.

② La garantie d'amélioration monotone.

valeur de l'équipe APRÈS le tour $\geq$ valeur AVANT (jamais de recul, prouvé)

Pourquoi c'est rare et précieux : la plupart des méthodes multi-agents espèrent progresser ; HAPPO le **garantit**, à la manière dont TRPO/PPO le garantissaient pour un agent seul. La cascade est précisément ce qui transporte cette garantie du solo vers le groupe.

Un exemple concret

Le chef décide de resserrer la formation ; **puis** le mitrailleur ajuste sa position de tir *en sachant* que la formation s'est resserrée ; **puis** le médecin se replace *en sachant* où sont désormais les deux autres. Personne n'optimise « dans le vide ». Si, au contraire, les trois s'étaient repositionnés simultanément en imaginant les autres immobiles, ils auraient pu se masquer mutuellement les angles de tir — une régression que la cascade évite.

Variantes & pièges

- **HATRPO** : la même idée avec la contrainte dure de TRPO (plus rigoureuse, plus lourde).
- **HASAC** : variante hors-politique (entropie maximale), plus économe en données.
- **MAT** (*Multi-Agent Transformer*) : traite l'équipe comme une *séquence* à décider l'un après l'autre — cousin moderne de l'idée de cascade.
- *Pièges* : l'ordre séquentiel coûte un peu en calcul ; et il faut un critique central bien conçu, comme pour MAPPO.

Pourquoi on l'utilise ici

Ton équipe est **hétérogène par conception**. HAPPO est taillé pour ça : il évite que les quatre se marchent dessus en se corrigeant en même temps, et il offre une **progression sûre** là où MAPPO « simple » suppose des agents semblables. C'est le moteur recommandé pour « 1 chef + 3 spécialistes ».

En dernier regard. HAPPO énonce une vérité politique : une communauté de rôles distincts ne tient pas par la simultanéité, mais par l'ordre du dialogue. On ne parle pas tous en même temps ; on s'écoute, on tient compte de ce que l'autre vient de faire. Adam Smith y voyait la division du travail ; Durkheim, la « solidarité organique » — cette cohésion paradoxale où c'est la différence des fonctions, non leur uniformité, qui soude le corps social. L'algorithme retrouve l'intuition : quatre êtres dissemblables deviennent une équipe non en agissant pareil, mais en s'ajustant tour à tour, chacun à sa place et au su des autres.