

QMIX & décomposition de valeur

« *Que l'intérêt de chacun serve le bien de tous* »

Le problème qu'il résout

À l'exécution, chaque soldat décide **seul**, avec ses seuls yeux (pas de vue d'ensemble, pas de temps pour délibérer). Mais la récompense est **collective**. Comment garantir que « chacun fait au mieux pour soi, localement » revienne à « l'équipe fait au mieux, globalement » ? Si l'on apprend une note d'équipe géante (dépendant des actions de tous), elle est impossible à utiliser sur le terrain (chacun devrait connaître les actions des autres). Si chacun apprend dans son coin (*Independent Q-Learning*), la coordination s'effondre. Il faut un pont entre les deux.

L'idée centrale

Construire la note d'équipe à partir des notes individuelles, selon une règle qui force la coïncidence des optima. Chaque agent a sa propre note ; une « note d'équipe » les combine ; et la combinaison est choisie de telle sorte que maximiser sa note individuelle revienne toujours à servir la note d'équipe. On apprend ensemble (avec la note d'équipe), on exécute séparément (chacun sa note).

Le mécanisme, pas à pas

1. Chaque agent a un réseau qui lui donne une **note** (valeur) pour chacune de ses actions possibles, à partir de sa seule observation.
2. Un **réseau mélangeur** combine ces notes individuelles en une **note d'équipe**, en s'aidant de l'état global (disponible à l'entraînement).
3. On entraîne le tout pour que la note d'équipe prédise bien la récompense future réelle (apprentissage par valeur, type Q-learning, avec mémoire de jeu).
4. **Contrainte clé** : le mélangeur est forcé d'être *monotone* (voir ④) — c'est ce qui garantit la coïncidence des optima.
5. À l'exécution, on jette le mélangeur : chaque agent choisit l'action de **sa** meilleure note.

Les formules, traduites

④ La règle de coïncidence (principe IGM).

meilleur choix de l'ÉQUIPE = (meilleur choix du soldat 1, ..., meilleur choix du soldat n)

Pour un littéraire : on veut que la somme des décisions « les meilleures pour soi » forme exactement la meilleure décision collective. Que l'égoïsme local et le bien commun pointent dans la même direction. Sans cette propriété, la décentralisation trahit l'équipe.

② La fabrication de la note d'équipe.

note d'équipe = mélange(note du soldat 1, ..., note du soldat n ; état global)

③ La règle de montée (monotonie).

si la note d'UN SEUL membre monte, la note d'équipe ne peut que monter ou rester égale

*Pourquoi cette règle garantit le ① : si améliorer un membre ne peut **jamais** nuire à l'équipe, alors chacun peut chercher son propre maximum sans risque pour le collectif. La monotonie est le pont entre l'individuel et le commun.*

④ **La hiérarchie d'expressivité.** VDN additionne simplement les notes (rudimentaire). QMIX les mélange de façon monotone mais **non linéaire**, en tenant compte de l'état (bien plus riche). QPLEX va plus loin encore (voir le piège).

Un exemple concret

Le mitrailleur « note » très haut l'action *suppression* quand l'ennemi est groupé ; le voltigeur note haut *avancer* quand il est couvert. Le mélangeur apprend que, **ensemble**, ces deux notes hautes valent une excellente note d'équipe (suppression + progression = manœuvre réussie). Chacun, en suivant sa propre note, déclenche la bonne combinaison — sans s'être concerté.

Variantes & pièges

- **La limite à connaître (capital).** Certaines manœuvres sont en **tout-ou-rien** : déborder à deux est excellent ; *un seul* qui s'élance sans couverture est *pire que rien*. Là, améliorer un seul membre **dégrade** l'ensemble — ce que la règle de montée **interdit de représenter**. QMIX est alors aveugle à ces tactiques.
- **VDN** (somme), **QTRAN** et **QPLEX** (qui lèvent la limite de monotonie, au prix d'un entraînement plus délicat), **Weighted QMIX** (corrige un biais).
- **Piège** : croire que QMIX peut tout représenter. Pour de la coordination « tout-ou-rien », il faut monter en gamme (QPLEX) ou passer à l'acteur-critique (MAPPO/HAPPO).

Pourquoi on l'utilise ici

C'est la base de l'apprentissage **par valeur** en équipe : très économe en données (il ressasse une mémoire de jeu). On le garde en réserve pour des actions discrètes, en sachant sa limite — et on

lui préfère HAPPO quand la coordination devient « tout-ou-rien ».

*En dernier regard. QMIX pose, sans le dire, la plus vieille question de la métaphysique : le tout est-il la somme de ses parties ? Sa règle de montée est un pari d'harmonie — l'idée, déjà chère à Leibniz, que le bien de chacun puisse composer le bien de tous. Et sa limite est tout aussi profonde : il existe des tous qui sont *plus* que la somme — la manœuvre coordonnée, l'accord choral, l'élan collectif — où le sens naît de la relation, non de l'addition. L'algorithme trace ainsi, à sa manière, la frontière exacte entre ce que le réductionnisme sait reconstruire et ce qui lui demeure, irréductiblement, étranger.*