

CMDP / Lagrangien

« Réussir la mission sans franchir la ligne rouge »

Le problème qu'il résout

Ton cahier des charges dit : « remplir la mission **et** rester en vie ». La tentation est de tout fondre dans une seule récompense : *réussite – pénalité_pertes*. Mauvaise idée. D'abord, comment fixer le taux de change entre « un objectif pris » et « un homme perdu » ? Tout chiffre est arbitraire. Ensuite — résultat mathématique — une simple somme pondérée **ne peut atteindre que certaines solutions** (la partie « convexe » des compromis possibles) : des plans pourtant excellents deviennent **inatteignables** quel que soit le réglage. La survie n'est pas un objectif à marchander librement ; c'est une **limite**.

L'idée centrale

Maximiser la mission sous une contrainte de pertes, et non additionner les deux. On ne cherche pas « un peu moins de morts contre un peu moins de mission » ; on cherche *la meilleure mission possible, tant que les pertes restent sous un seuil que tu fixes*. Pour résoudre ce problème « sous contrainte », on le transforme astucieusement en un problème ordinaire avec un **curseur auto-réglé**.

Le mécanisme, pas à pas

1. On définit **deux** signaux : la **récompense** (réussite de mission) et le **coût** (les pertes).
2. On fixe un **seuil** de coût acceptable (« je n'accepte pas plus de tant de pertes attendues »).
3. On introduit un curseur λ (le « prix du risque »).
4. On entraîne la politique à maximiser : *réussite – $\lambda \times$ (dépassement du seuil)*.
5. **On ajuste λ automatiquement** : si les pertes dépassent le seuil, λ monte (la prudence devient chère) ; si elles repassent dessous, λ redescend (l'audace revient). Ce va-et-vient converge vers le juste niveau.

Les formules, traduites

① L'objectif sous contrainte.

maximiser (réussite de mission) TANT QUE (pertes attendues) $\leq$ seuil que tu choisis

*Pour un littéraire : l'ordre de mission réaliste — « prends l'objectif, mais je n'accepte pas plus de tant de pertes ». Le seuil, c'est le *niveau de risque acceptable*.*

② Le curseur (le « lagrangien »).

$$\text{note} = (\text{réussite de mission}) - \lambda \cdot (\text{dépassement du seuil de pertes})$$

Pourquoi ce tour de passe-passe marche : transformer une contrainte en pénalité réglable est une technique classique d'optimisation (les « multiplicateurs de Lagrange »). Le génie ici est que λ n'est pas fixé à la main : il s'apprend.

③ Le réglage automatique de λ .

trop de pertes $\rightarrow \lambda$ monte (prudence chère) ; pertes sous le seuil $\rightarrow \lambda$ baisse (audace permise)

En clair : tu ne règles pas un compromis figé ; tu poses une **limite**, et le curseur trouve de lui-même l'agressivité qui la respecte, en se resserrant ou se relâchant au fil de l'apprentissage.

Un exemple concret

Au début, les agents foncent : pertes au-dessus du seuil. λ grimpe ; soudain, chaque mort « coûte » très cher dans la note, et la politique apprend à temporiser, à mieux se couvrir, à attendre la suppression avant d'avancer. Les pertes retombent sous le seuil ; λ se détend ; un peu d'audace revient. Le système oscille puis se stabilise sur le **plan le plus offensif compatible avec le seuil de pertes** — exactement ce qu'on voulait.

Variantes & pièges

- **CPO** : impose la contrainte par une région de confiance (plus rigoureux).
- **MAPPO-Lagrangian / MACPO** : les versions **multi-agents sous contrainte** — celles de ton projet.
- **CVaR** (raffinement avancé) : au lieu de borner la *moyenne* des pertes, borner le *pire cas* (la queue de distribution) — plus réaliste pour du combat, mais plus exigeant.
- *Pièges* : λ qui oscille trop (réglage de sa vitesse d'ajustement) ; et la contrainte n'est garantie qu'à **convergence**, pas forcément pendant l'exploration (d'où le besoin de sécurité pendant l'entraînement).

Pourquoi on l'utilise ici

C'est la traduction **exacte** de « remplir la mission et rester en vie », avec la survie posée comme contrainte d'équipe. Le curseur λ régule l'audace tactique tout seul — tu n'as qu'à fixer le seuil de pertes acceptable, le reste s'ajuste.

En dernier regard. Ce curseur tranche une vieille querelle morale. Le conséquentialiste met tout dans une même balance et calcule le meilleur solde ; le déontologue pose des limites qu'aucun bénéfice ne saurait acheter. Le CMDP fait les deux à la fois : il maximise un résultat, mais sous une frontière qu'il traite comme inviolable. Et son λ — ce prix du risque qui s'élève à mesure qu'on approche de la limite — dit quelque chose de troublant et de juste : plus on s'approche de l'inacceptable, plus la prudence doit coûter cher, jusqu'à devenir prohibitive. Mettre un prix sur le risque sans jamais mettre un prix sur l'interdit : c'est, peut-être, une définition opératoire de la sagesse pratique.