

PBT — Entraînement par population

« Une évolution darwinienne des entraînements »

Le problème qu'il résout

Tout entraînement RL dépend d'une foule de **réglages** (vitesse d'apprentissage, dose d'exploration, poids divers...) dont on ne connaît pas d'avance les bonnes valeurs. La méthode habituelle — essayer une combinaison, attendre des heures, recommencer — est lente et coûteuse. Pire : les bons réglages **changent au cours** de l'entraînement (au début il faut explorer, plus tard il faut affiner). Un réglage fixe est donc forcément sous-optimal à un moment ou un autre.

L'idée centrale

Entraîner toute une population en parallèle, et laisser les bonnes recettes se répandre et muter, en continu. Plutôt que de chercher les bons réglages d'avance, on les fait **évoluer** pendant l'entraînement : sélection des meilleurs, copie, petites mutations. La nature trouve à notre place.

Le mécanisme, pas à pas

1. On lance **N entraînements en parallèle**, chacun avec des réglages un peu différents.
2. À intervalles réguliers, on **évalue** chaque membre (sa performance du moment).
3. **Exploiter** : un membre nettement moins bon **abandonne** son état et **copie** celui d'un membre nettement meilleur (poids du réseau et réglages).
4. **Explorer** : juste après avoir copié, il **perturbe** légèrement les réglages (au hasard, un peu) — autant de tentatives d'aller plus loin que le « parent ».
5. On laisse tourner. La qualité moyenne monte, et les réglages **s'adaptent dans le temps** sans qu'on touche à rien.

Les formules, traduites

① Exploiter (sélection).

si un membre est nettement moins bon → il adopte l'état et les réglages du meilleur

Pour un littéraire : les recettes perdantes sont abandonnées ; les gagnantes se reproduisent.

② Explorer (mutation).

après avoir copié → on perturbe un peu les réglages (légèrement, au hasard)

Pourquoi les deux ensemble : copier seul fige la population sur un unique gagnant (on s'appauvrit) ; muter seul disperse sans capitaliser. **Sélection + variation** : c'est la formule même de l'évolution. La diversité de la population est une assurance contre l'impasse.

Un exemple concret

Cinq entraînements de ton équipe tournent de front. Au bout d'une heure, trois stagnent, deux progressent vite (ils avaient, par chance, une meilleure dose d'exploration). Les trois retardataires **copient** l'un des deux bons, puis **perturbent** légèrement leurs réglages — l'un essaie un peu plus d'exploration, l'autre un peu moins. Une heure plus tard, c'est l'une de ces *mutations* qui mène, et les autres la copient à leur tour. Sans intervention, la population a trouvé un réglage que tu n'aurais pas deviné — et qui, en plus, **a changé** au bon moment.

Variantes & pièges

- Se combine avec presque tout : PBT **par-dessus** MAPPO, ou **par-dessus** l'auto-jeu (c'est exactement ce que faisait AlphaStar : PBT + ligue).
- *Pièges* : il faut **plusieurs entraînements de front** (gourmand — mais ta machine s'y prête) ; une mauvaise mesure de « qui est le meilleur » fausse toute la sélection ; et la population peut **converger trop vite** vers un seul type si l'on n'entretient pas assez de diversité.

Pourquoi on l'utilise ici

PBT **règle les réglages tout seul** (gros gain de temps et de performance) et **diversifie les stratégies** (assurance contre l'impasse). Il exploite à merveille ta workstation, capable de faire tourner plusieurs entraînements simultanés. On l'ajoute *en dernier*, comme enveloppe, une fois la base solide.

En dernier regard. PBT incarne une épistémologie sans architecte : le progrès n'y vient pas d'un plan génial, mais de la variation aveugle suivie d'une sélection impitoyable. C'est l'idée de Darwin, que Popper transposa à la connaissance — nos théories, disait-il, « meurent à notre place » : on les laisse échouer pour ne pas échouer soi-même. Leçon d'humilité : on n'a pas besoin de savoir d'avance ce qui est juste, pourvu qu'on entretienne assez de diversité et qu'on accepte d'éliminer ce qui échoue. La sagesse n'est pas toujours dans le concepteur ; parfois, elle est répartie dans la population — et dans le temps qu'on lui laisse.